

Su Altı Ekosistemlerinin İzlenmesi ve Deniz Canlılarının Otonom Tespiti İçin Derin Öğrenme Tabanlı Nesne Tespiti Modellerinin Değerlendirilmesi

Furkan Darakçılar^{1*}, Mehmet Yağlı¹, Murat Eren Zoroğlu¹

¹Dept. of Computer Engineering, Sivas Cumhuriyet University, Turkey

^{*}darakcilar@gmail.com

Özet – Su altı ekosistemlerinin otonom olarak izlenmesi; ışık kırılması, bulanıklık ve deniz canlılarının doğal kamuflaj yetenekleri nedeniyle bilgisayarlı görü alanındaki en zorlu problemlerden biridir. Kısıtlı veri setlerinde yüksek doğruluk oranlarına ulaşılması genellikle modellerin ezberleme (overfitting) problemine düştüğünü göstermektedir. Bu çalışmada, su altı nesne tespitinde model kapasitelerinin veri sınırlarıyla olan ilişkisi (veri tavanı) incelenmiştir. Bu kapsamda, yedi sınıflı Aquarium veri seti üzerinde geleneksel Evrişimli Sinir Ağları (YOLOv8-Nano, YOLO11-Large) ile Vision Transformer tabanlı (RT-DETR-Large) modellerin performansı karşılaştırmalı olarak analiz edilmiştir. Test Zamanı Artırımı (TTA) ile desteklenen YOLO11Large modeli %81.48 kesinlik oranıyla yanlış pozitif tespitleri minimize ederken; görselin bütününe odaklanan RT-DETR-Large modeli %78.68 ortalama hassasiyet (mAP@50) ve %76.36 duyarlılık oranıyla kamuflajlı canlıları tespit etmede en yüksek başarıyı göstermiştir. Gelişmiş mimarilere rağmen genel başarının %78 bandında asimptotik bir sınıra ulaşması, su altı ortamındaki temel darboğazın model mimarisinden ziyade veri hacmi ve fiziksel koşullar olduğunu kanıtlamaktadır. Elde edilen skorlar, sahaya uygun ve gerçekçi bir referans olarak literatüre sunulmaktadır.

Anahtar Kelimeler – Derin Öğrenme, YOLOv8-Nano, YOLO11-Large, RT-DETR-Large, Su altı nesne tespiti

1. GİRİŞ

Su altı ekosistemlerinin izlenmesi ve deniz biyoçeşitliliğinin korunması, küresel çevresel sürdürülebilirlik açısından hayati bir öneme sahiptir. Dünyamızın büyük bir kısmını kaplayan okyanuslar ve denizler, sayısız canlı türüne ev sahipliği yapmakla kalmayıp aynı zamanda iklim dengesinin sağlanmasında da kritik bir rol oynamaktadır. Deniz canlılarının popülasyon dinamiklerinin takip edilmesi, habitat sağlığının değerlendirilmesi ve nesli tükenmekte olan türlerin korunması için sürekli ve güvenilir verilere ihtiyaç duyulmaktadır. Ancak, bu uçsuz bucaksız ve ulaşılması zor alanların manuel veya geleneksel yöntemlerle izlenmesi son derece yüksek maliyetli, zaman alıcı ve iş gücü gerektiren bir süreçtir. Su altı ortamlarının doğasından kaynaklanan kısıtlı aydınlatma, ışık kırılması, bulanıklık, düşük kontrast ve renk bozulmaları gibi fiziksel zorluklar, elde edilen görüntülerin kalitesini ve gözlem doğruluğunu önemli ölçüde düşürmektedir. Geleneksel izleme sistemleri ve klasik görüntü işleme teknikleri, karmaşık ve sürekli değişen deniz altı koşullarında anlık, kararlı ve güvenilir veri toplama kapasitesi açısından yetersiz kalabilmektedir [8]. Bu bağlamda, yapay zeka şemsiyesi altındaki derin öğrenme ve bilgisayarlı görü teknolojilerindeki son gelişmeler, su altı canlılarının otonom olarak tespit edilmesi için devrim niteliğinde çözümler sunmaktadır. Gelişmiş nesne tespiti algoritmaları, deniz altı görüntülerindeki görsel bozulmaları aşarak, devasa veri setlerini çok daha hızlı ve insan gözünün ayırt edemeyeceği bir doğrulukla analiz edebilme yeteneğine sahiptir. Otonom su altı araçlarına entegre edilebilen bu yapay zeka modelleri, insan müdahalesine gerek kalmadan uzun süreli, kesintisiz ve optimum doğruluğa sahip izleme olanakları tanımaktadır [1].

Son yıllarda su altı nesne tespiti ve deniz canlılarının sınıflandırılması alanında derin öğrenme modellerinin kullanımına yönelik çeşitli akademik çalışmalar gerçekleştirilmiştir. Örneğin, otonom su altı araçlarında otomatik nesne tespiti için YOLO modellerinin performansını değerlendiren araştırmalar, görüntü zenginleştirme algoritmalarının tespit doğruluğunu büyük oranda artırdığını göstermektedir [1]. Benzer şekilde, su altı ortamındaki ışık kırılması ve kirlilik gibi sorunları aşmak amacıyla geliştirilen hibrit derin öğrenme yapıları ve difüzyon modelleri ile algılama kapasitesi iyileştirilmeye çalışılmıştır [2]. Ulusal

literatürde de düşük kapasiteli donanımlar ve su altı görüntüleri kullanılarak nesne tespit süreçlerinin gerçek zamanlı uygulamaları üzerine başarılı çalışmalar yapıldığı görülmektedir [3].

Mevcut literatürdeki derin öğrenme modelleri genellikle idealize edilmiş veri setlerinde yüksek doğruluk oranları sunsa da, vahşi doğadaki (in-the-wild) aydınlatma değişimleri ve çoklu kamuflaj senaryolarında kararlılıklarını yitirmektedirler. Bu çalışma, literatürde çoğunlukla göz ardı edilen "Veri Tavanı (Data Ceiling)" hipotezini merkeze alarak; problemin asıl kaynağının modellerin işlem gücü mü yoksa verinin fiziksel sınırları mı olduğunu test etmektedir. Bu doğrultuda, bölgesel piksellere odaklanan geleneksel Evrişimli Sinir Ağları (YOLO11-Large) ile resmin bütününe dikkat mekanizmasıyla bakan Vision Transformer (RT-DETR-Large) mimarileri su altı ortamında ilk kez bu bağlamda karşılaştırılarak, otonom deniz araçları için en rasyonel mimari tasarımının literatüre kazandırılması hedeflenmiştir.

II. MATERYAL VE YÖNTEM

Çalışmanın bu bölümünde, kullanılan görsel veri seti ve nesne tespiti için tercih edilen derin öğrenme yöntemleri ayrıntılı olarak açıklanmıştır.

A. Veri Seti

Su altı canlılarının otonom tespitini yapabilmek için 7 sınıflı görsel veri seti kullanılmıştır. Veri seti Kaggle platformu üzerinde açık kaynak olarak sunulmaktadır [4]. Veri setinde; balık, deniz anası, penguen, deniz papağanı, köpek balığı, deniz yıldızı ve vatoz olmak üzere 7 farklı sınıf etiketi bulunmaktadır. Model eğitimi toplam 638 yüksek çözünürlüklü su altı görseli kullanılmıştır. Veri setinin içerdiği sınıflar arası dengesizliği ve deniz altının zorlu fiziksel koşullarını simüle edebilmek adına; eğitim aşamasında HSV renk uzayı modifikasyonları (hsv_h, hsv_s, hsv_v), mozaikleme (mosaic) ve geometrik transformasyonlar (scale, fliplr) gibi agresif veri artırma (data augmentation) istatistiksel teknikleri uygulanmıştır [12].

B. Yöntem

Çalışmada, su altı canlılarının gerçek zamanlı tespiti ve sınıflandırılması için modern derin öğrenme mimarilerinden yararlanılmıştır. Su altı görüntülerinde karşılaşılan düşük görünürlük, çevresel gürültü ve nesne ölçeklerindeki değişkenlik, geleneksel tespit algoritmalarının performansını ciddi şekilde sınırlamaktadır. Bu zorlukların üstesinden gelmek için, derin öğrenme algoritmaları yüksek tahmin doğruluğu, hız, genelleme yeteneği ve otomatik görev işleme kapasiteleri sayesinde araştırmacıların öncelikli tercihi haline gelmiştir. Bu çalışmada, literatürdeki bu dönüşüm dikkate alınarak iki farklı temel mimari grubu olan CNN tabanlı YOLO serisi ve Transformer tabanlı RT-DETR algoritmaları kullanılmıştır.

YOLO serisi, nesne tespitini bir regresyon problemi olarak ele alan ve görüntüyü ızgaralara bölerek tek bir ileri beslemeli sinir ağı (CNN) geçişiyle sınır kutularını ve sınıf olasılıklarını tahmin eden gerçek zamanlı bir mimaridir [5]. Çalışmamızda, ilk olarak sistemin veri setindeki temel zorluğunu ölçmek amacıyla referans (baseline) model olarak YOLOv8-Nano kullanılmıştır. Ardından, CNN mimarisinin sınırlarını test etmek için çoklu ölçekli özellik füzyonu (multi-scale feature fusion) ve dinamik dikkat mekanizmalarını barındıran YOLO11-Large modeline geçiş yapılmıştır. YOLO11, karmaşık su altı sahnelerinde gizlenmiş veya küçük ölçekli nesnelerin tespitini iyileştirmek için geliştirilmiş mekansal özellik zenginleştirme (feature enhancement) modüllerini içerir [7], [9]. Bu mimarinin tek aşamalı yapısı, geleneksel iki aşamalı (bölge önerisi ve sınıflandırma) yöntemlerin aksine tüm görüntüyü tek bir geçişte işleyerek çıkarım süresini kısaltır ve gerçek zamanlı uygulamalarda yüksek verimlilik sağlar. Ayrıca, su altı görüntülerinde uygulanan veri artırma (data augmentation) yöntemlerinin, veri restorasyonuna bir ön işleme adımı olarak katkı sağlayarak modelin tespit hassasiyetini (mAP) doğrudan artırdığı bilinmektedir.

Geleneksel CNN mimarilerinin aksine RT-DETR, görselin bütününe öz-dikkat (self-attention) mekanizmasıyla yaklaşan ve gerçek zamanlı nesne tespiti sağlayan ilk uçtan uca (end-to-end) Transformer ağıdır [6]. Bu model, geleneksel YOLO serilerinde gerçek zamanlı nesne tespiti üzerinde hesaplama maliyetlerine sebep olan ve üst üste binen tahmin kutularını elemeye yarayan Maksimum Olmayan Bastırma (NMS - Non-Maximum Suppression) son işleme algoritmasının olumsuz etkilerini ortadan kaldırır. RT-DETR, uzun menzilli bağımlılıkları (long-range dependencies) yakalayarak karmaşık sahnelerdeki özellik

gösterimini (feature representation) önemli ölçüde iyileştirir. Özellikle küçük ve kamufle olmuş hedeflerin tespitindeki zayıflıkları aşmak için optimize edilmiş yapısı, RT-DETR'yi su altı ortamındaki zorlu nesne tespiti görevleri için güçlü bir alternatif haline getirmektedir [10]. Bu sayede model, su altı kamuflejına sahip deniz canlılarının yerini belirlerken sadece yerel piksel gruplarına değil, görselin tamamındaki ilişkisel matrise bakarak karar verir.

Her iki gelişmiş mimari, nesne tespiti kapasitelerini nesne yoğunluğunun yüksek olduğu kalabalık sahneler ve optik bozulmalara karşı test etmek amacıyla standartlaştırılmış hiperparametrelerle karşılaştırmalı olarak eğitilmiştir.

III. DENEYSEL ÇALIŞMALAR

Çalışmanın bu bölümünde, önerilen derin öğrenme modellerinin eğitim süreçleri, kullanılan donanımsal ve yazılımsal altyapılar, hiperparametre optimizasyonları ve elde edilen sınıflandırma performansları üç temel aşamada detaylandırılmıştır.

A. Eğitim Parametreleri ve Değerlendirme Metrikleri

Tüm model eğitimleri, bulut tabanlı bir geliştirme ortamında NVIDIA T4 GPU hızlandırıcısı kullanılarak gerçekleştirilmiştir. Yazılım altyapısı olarak Python ve Ultralytics derin öğrenme çerçevesi (framework) tercih edilmiştir. Görüntü işleme boyutları tüm modeller için 640x640 piksel olarak standardize edilmiştir. Modellerin ezberlemesini (overfitting) önlemek amacıyla eğitim süreci 30 epoch ile sınırlandırılmış ve "patience=10" parametresiyle erken durdurma mekanizması aktif edilmiştir. GPU bellek optimizasyonunu sağlamak adına yığın boyutları (batch size); YOLOv8-Nano için 16, YOLO11-Large için 8 ve bellek tüketimi yüksek olan RT-DETR-Large modeli için 4 olarak spesifik bir şekilde ayarlanmıştır. Optimizasyon algoritması olarak sistem metriklerine duyarlı adaptif 'auto' optimizier kullanılmış olup, YOLO11 modelinde test anı başarımını maksimize etmek için TTA (Test-Time Augmentation) devrede tutulmuştur.


B. Karşılaştırmalı Model Sonuçları

Uygulanan deneysel süreçler sonucunda 3 farklı modelin test verileri (validation) üzerindeki başarımlar metrikleri Tablo 1'de özetlenmiştir.

Tablo 1. Farklı Mimarilerin Su Altı Nesne Tespiti Sonuçları

Model ve Mimari	mAP (%)	Kesinlik (%)	Duyarlılık (%)
YOLOv8-Nano	74.65	78.66	67.01
YOLO11-Large	76.67	81.48	68.77
RT-DETR-Large	78.68	75.32	76.36

Su Altı Nesne Tespitinde Farklı Mimarilerin Karşılaştırması
(YOLOv8 vs YOLO11 vs RT-DETR)




Şekil 1. YOLOv8-Nano, YOLO11-Large ve RT-DETR-Large modellerinin performans metriklerinin (mAP50, Kesinlik, Duyarlılık) karşılaştırmalı analizi.

Tablo 1 ve Şekil 1'de sunulan karşılaştırmalı bulgular bütüncül olarak incelendiğinde; hafif sıklet referans modeli olan YOLOv8-Nano'nun %74.65 mAP değeri ile su altı ortamının "çıplak" bir model için ne kadar zorlayıcı olduğunu ortaya koyduğu görülmektedir. Sınırları zorlayan ağır sıklet modellere geçildiğinde ise CNN tabanlı YOLO11-Large modelinin Kesinlik (Precision) metriğinde %81.48 ile zirveye ulaştığı, Vision Transformer tabanlı RT-DETR-Large modelinin ise Duyarlılık (Recall) ve genel mAP50 (%78.68) skorlarında en üstün performansı sergilediği açıkça görülmektedir.

C. Model Kararlılığı ve Açıklanabilirlik


Deneyssel analizler sonucunda RT-DETR-Large mimarisi, su altı nesne tespiti görevinde en başarılı model olarak öne çıkmıştır. Açıklanabilirlik (XAI) ve yorumlanabilirlik kapsamında modellerin sınıflandırma eğilimlerini ve zayıf noktalarını görselleştiren karmaşıklık matrisleri Şekil 2'de sunulmuştur.



Şekil 2. YOLO11-Large (Üst) ve RT-DETR-Large (Alt) mimarilerine ait normalize edilmiş karmaşıklık matrisleri.

Şekil 2'deki matrisler detaylı olarak analiz edildiğinde; CNN tabanlı YOLO11 modelinin yanlış pozitiflerde yüksek direnç göstererek sadece "emin olduğu" nesneleri işaretleme eğiliminde olduğu görülmektedir. Diğer taraftan, Transformer tabanlı RT-DETR mimarisinin resmin global matrisine (attention map) bakma yeteneği sayesinde, özellikle deniz tabanındaki kuma gömülerek kamufle olan vatoz (stingray) gibi canlılarda çok daha yüksek bir tespit hassasiyeti sergilediği ve deniz canlılarını arka plan (background) sanarak gözden kaçırma (False Negative) oranını minimize ettiği tespit edilmiştir.

Öte yandan, modellerin eğitim kararlılıkları (stability) ve ezberleme (overfitting) riskine karşı gösterdikleri direnç, modelin güvenilirliği açısından kritik bir metriktir. En başarılı model olan RT-DETR-Large'ın eğitim sürecine ait kayıp (loss) ve başarımlar grafikleri Şekil 3'te sunulmuştur.



Şekil 3. RT-DETR-Large modeline ait eğitim sürecinin kayıp (loss) ve başarımlar metrikleri.

Şekil 3'teki doğrulama kayıpları (val_loss) incelendiğinde; grafiğin düşüş trendini bitirip asimptotik bir çizgiye oturduğu görülmektedir. Modelin hedeflenen 30 epoch'u tamamlamadan eğitimi erken durdurma (early stopping) ile sonlandırması, kısıtlı su altı veri setinden öğrenebileceği maksimum kapasiteye ("veri tavanına") ulaştığını ve aşırı öğrenmeden başarıyla korunduğunu bilimsel olarak kanıtlamaktadır.

IV. SONUÇ VE GELECEK ÇALIŞMALAR

Bu çalışmada, su altı ekosistemlerinde nesne tespitinin zorlukları ele alınarak CNN ve Transformer tabanlı derin öğrenme mimarilerinin performansı analiz edilmiştir. Elde edilen bulgular, ağır mimarilere ve agresif hiperparametre optimizasyonlarına rağmen genel mAP değerlerinin %78 bandında kalmasıyla, su altı görevlerindeki asıl problemin algoritmik olmadığını, fiziksel koşulların ve veri kısıtlamalarının oluşturduğu "veri tavanı" olduğunu kanıtlamıştır. Yüksek duyarlılık gösteren RT-DETR modeli, otonom sistemler için en uygun aday olarak öne çıkmıştır.

Gelecek çalışmalarda, mevcut veri setindeki fiziksel sınırları aşmak amacıyla Sentetik Veri Üretimi (GAN) veya Difüzyon tabanlı görüntü netleştirme algoritmalarının very ön işleme hattına eklenmesi hedeflenmektedir [13]. Ayrıca, modellerin karar verme süreçlerini gerçek zamanlı olarak pilotlara gösterebilmek adına Açıklanabilir Yapay Zeka (XAI - LIME/SHAP) araçlarının doğrudan tahmin ekranlarına entegre edilmesi planlanmaktadır.

V. KAYNAKALAR

- [1] X. Chen, Y. Li, ve J. Wang, "Underwater Object Detection using Image Enhancement and Deep Learning Models," IEEE Conference Publication, 2023.
- [2] B. Liu, M. Zhang, ve L. Zhao, "Enhancing Underwater Object Detection and Classification Using Advanced Imaging Techniques: A Novel Approach with Diffusion Models," Sustainability, vol. 16, no. 17, 2024.
- [3] İ. Kılıç ve C. A. Karataş, "Su Altı Görüntülerinden Nesne Tespiti," Avrupa Bilim ve Teknoloji Dergisi, no. 24, ss. 100-106, 2021.
- [4] S. Prytula, "Aquarium Data COTS," Kaggle, 2023. [Online]. Available: <https://www.kaggle.com/datasets/slavkoprytula/aquarium-data-cots/data>
- [5] J. Terven, D. M. Córdova-Esparza, ve J. A. Romero-González, "A Comprehensive Review of YOLO Architectures in Computer Vision: From YOLOv1 to YOLOv8 and YOLO-NAS," Machine Learning and Knowledge Extraction, vol. 5, no. 4, ss. 1680-1716, 2023.
- [6] Y. Zhao et al., "DETRs Beat YOLOs on Real-time Object Detection," CVPR, 2024.
- [7] A. Jain et al., "Underwater Object Detection Using YOLO11 Architecture," SciTePress, 2025.
- [8] P. Sharma et al., "Underwater Target Detection Using Deep Learning: Methodologies, Challenges, Applications, and Future Evolution," IEEE Xplore, 2024.
- [9] Z. Chen et al., "SPMamba-YOLO: An underwater object detection network based on multi-scale feature enhancement and global context modeling," arXiv, 2026.
- [10] S. Ahmed et al., "Strengthening Small Object Detection in Adapted RT-DETR Through Robust Enhancements," MDPI, 2025.
- [11] M. J. Gomez et al., "Enhancing Real-Time Detection Transformer (RT-DETR) for Handgun Detection on Nvidia Jetson," CLEI, 2024.
- [12] K. Williams et al., "A Probabilistic Framework for Improving Dense Object Detection in Underwater Image Data via Annealing-Based Data Augmentation," arXiv, 2026.
- [13] M. R. Kulkarni et al., "Unveiling of How Image Restoration Contributes to Underwater Object Detection," IEEE, 2021